

ΠΟΛΥΤΕΧΝΕΙΟ ΚΡΗΤΗΣ

1^η Σειρά Ασκήσεων



Μία αναφορά για το μάθημα

Στατιστική Μοντελοποίηση και Αναγνώριση Προτύπων

ΣΤΑΥΡΟΠΟΥΛΟΥ ΕΛΕΝΗ Α.Μ.: 2019030070

ΓΙΑΟΥΠΙ ΚΛΕΪΝΤΑ Α.Μ.: 2019030132




Χανιά, 2024

Θέμα 1 - Principal Component Analysis (PCA)

Σκοπός της συγκεκριμένης άσκησης ήταν η εξοικείωση με την μέθοδο Principal Component Analysis, η οποία χρησιμοποιείται για την μείωση των διαστάσεων των δεδομένων.


Μέρος 1

Αφού διαβάσαμε το αρχείο 'data/breast_cancer_data.csv', επιλέξαμε ενδεικτικά κάποια ζεύγη χαρακτηριστικών και απεικονίσαμε τα δείγματα στον 2D χώρο. Παρατηρήθηκαν διαφορετικοί διαχωρισμοί μεταξύ των κλάσεων σε κάθε απεικόνιση. Για παράδειγμα, το ζεύγος χαρακτηριστικών 24-25 διαχωρίζει καλύτερα τις κλάσεις σε σχέση με το ζεύγος 1-2. Αυτό σημαίνει ότι μπορεί να χρησιμοποιηθεί για καλύτερα αποτελέσματα στη διάκριση μεταξύ καλοήθων και κακοήθων όγκων.




Έπειτα, πραγματοποιήσαμε κανονικοποίηση των δεδομένων με μέση τιμή 0 και διασπορά 1, ώστε να μην υπάρχουν πολύ μεγάλες διαφορές μεταξύ των τιμών των χαρακτηριστικών και ο PCA να μην αντιμετωπίζει προβλήματα, όπως για παράδειγμα αλλαγή στην κατεύθυνση της μέγιστης διασποράς. Παρατηρήσαμε μείωση του εύρους τιμών των κανονικοποιημένων δεδομένων σε σχέση με τα αρχικά και συγκέντρωση τους γύρω από το 0, ενώ επίσης τα δεδομένα είναι λιγότερο απλωμένα με μέγιστες/ελάχιστες x,y τιμές κοντά στο +/- 2, σε αντίθεση με τα μη κανονικοποιημένα που παίρνουν τιμές από 10 έως 30.

Επίσης, υπολογίσαμε τις κύριες συνιστώσες του αλγορίθμου PCA και τις σχεδιάσαμε στην ίδια γραφική με τα αρχικά δείγματα. Παρατηρήσαμε ότι η 1η κύρια συνιστώσα (με το κόκκινο χρώμα) έχει μεγαλύτερο μήκος από την 2η, γεγονός που δείχνει ότι τα δεδομένα είναι περισσότερο διασκορπισμένα κατά μήκος της 1ης συνιστώσας. Αξίζει να αναφερθεί ότι οι κύριες συνιστώσες φαίνεται να είναι ορθογώνιες, το οποίο είναι μια θεμελιώδης ιδιότητα του PCA. Αυτό σημαίνει ότι η διακύμανση των δεδομένων που καταγράφεται από μία συνιστώσα δεν επικαλύπτεται με τη διακύμανση που καταγράφεται από την άλλη.



Υπολογίσαμε τη συνεισφορά που έχει κάθε κύρια συνιστώσα στην συνολική διακύμανση έτσι ώστε να πραγματοποιηθεί μείωση των διαστάσεων από 2D σε 1D.


```
Explained Variance(1st PC = 0.687891) (2nd PC = 0.312109)
1st Principal Component = 0.707107 0.707107
```



Αφού προβάλλαμε τα δεδομένα σε χώρο μικρότερων διαστάσεων, τα ανακτήσαμε προσεγγιστικά αναπαράγοντάς τα ξανά στον αρχικό χώρο υψηλών διαστάσεων.

Projection of the first example: -1.058683


Approximation of the first example: -0.748602 -0.748602



Όταν χρησιμοποιείται η πρώτη κύρια συνιστώσα, τα αρχικά σημεία δεδομένων παραμένουν στον 2D χώρο τους, ενώ τα ανακτημένα σημεία δεδομένων ευθυγραμμίζονται κατά μήκος της γραμμής που ορίζεται από την κύρια συνιστώσα. Οι συνδεόμενες γραμμές απεικονίζουν τη διαδικασία προβολής και ανάκτησης και η διασπορά των ανακτημένων σημείων σχηματίζει μια ευθεία γραμμή σε 2D.

Ακολουθώντας, επαναλάβαμε την ανάλυση PCA χρησιμοποιώντας αυτή τη φορά όλο το διάνυσμα και των 30 χαρακτηριστικών. Με την προβολή των δειγμάτων στις 2 κύριες συνιστώσες και την απεικόνισή τους, παρατηρήσαμε ότι η 1η κύρια συνιστώσα δεν άλλαξε ιδιαίτερα, πιθανώς επειδή κάνει capture το ισχυρότερο σήμα από τα δεδομένα, το οποίο δεν αλλάζει σημαντικά ακόμη και με περισσότερα χαρακτηριστικά. Ωστόσο, η 2η κύρια συνιστώσα άλλαξε πιο αισθητά καθώς προσαρμόζεται ώστε να κάνει capture το 2ο ισχυρότερο σήμα στο πλαίσιο όλων των διαθέσιμων χαρακτηριστικών.

```
Explained Variance(1st PC = 0.430518) (2nd PC = 0.207239  
1st Principal Component = 0.206988 0.106123
```



Μέρος 2

Αρχικά, απεικονίσαμε τα πρώτα 100 πρόσωπα.




Κατόπιν, σχεδιάσαμε τις πρώτες 36 κύριες συνιστώσες του αλγορίθμου PCA εφαρμόζοντας standardization.



Παρατηρούμε με μια πρώτη ματιά ότι οι ανακτημένες εικόνες είναι θολές αλλά μοιάζουν με τις αρχικές, όμως, υπάρχει εμφανής αλλοίωση των χαρακτηριστικών των προσώπων. Το κάθε ιδιοδιάνυσμα περιέχει πληροφορία, όπως η σκίαση, η οποία είναι αρκετή για να σχηματιστεί μια εικόνα.

Στην συνέχεια, μειώσαμε την διάσταση των δειγμάτων σας χρησιμοποιώντας τις 100 πρώτες κύριες συνιστώσες.




Δοκιμάσαμε να επαναλάβουμε την διαδικασία χρησιμοποιώντας διαφορετικό αριθμό από κύριες συνιστώσες.


Για 10 συνιστώσες



Για 50 συνιστώσες



Για 200 συνιστώσες



Παρατηρούμε ότι όσο περισσότερες συνιστώσες χρησιμοποιούμε για να ανακτήσουμε τις εικόνες τόσο πιο κοντά θα πλησιάζουν στις πραγματικές εικόνες.

Θέμα 2 - Linear Discriminant Analysis (LDA)

$$P(w_A) = 0,4, \quad \mu_A = \begin{bmatrix} 0 \\ 2 \end{bmatrix}, \quad \mu_B = \begin{bmatrix} 2 \\ 0 \end{bmatrix}, \quad \Sigma_A = \begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix}, \quad \Sigma_B = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}$$

1) Για το μέγιστο FDR έχουμε: $w = S_w^{-1} \cdot (\mu_A - \mu_B)$, όπου:

$$\bullet \mu_A - \mu_B = \begin{bmatrix} 0 \\ 2 \end{bmatrix} - \begin{bmatrix} 2 \\ 0 \end{bmatrix} = \begin{bmatrix} -2 \\ 2 \end{bmatrix}$$

• Ο πίνακας διασποράς (within-class scatter matrix):

$$S_w = \sum_{i=1}^2 P_i \Sigma_i = P(w_A) \cdot \Sigma_A + (1 - P(w_A)) \cdot \Sigma_B = 0,4 \cdot \begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix} + 0,6 \cdot \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix} = \begin{bmatrix} 2,4 & 1 \\ 1 & 2,6 \end{bmatrix}$$

$$\bullet \text{Ο αντίστροφός του: } S_w^{-1} = \frac{1}{2,4 \cdot 2,6 - 1 \cdot 1} \cdot \begin{bmatrix} 2,6 & -1 \\ -1 & 2,4 \end{bmatrix} = \frac{1}{5,24} \begin{bmatrix} 2,6 & -1 \\ -1 & 2,4 \end{bmatrix} = \begin{bmatrix} 0,496 & -0,191 \\ -0,191 & 0,458 \end{bmatrix}$$

Οπότε, το διάνυσμα προβολής: $w = S_w^{-1} (\mu_A - \mu_B) =$

$$= \begin{bmatrix} 0,496 & -0,191 \\ -0,191 & 0,458 \end{bmatrix} \cdot \begin{bmatrix} -2 \\ 2 \end{bmatrix} = \begin{bmatrix} -1,374 \\ 1,298 \end{bmatrix} \quad **$$

2) Η προβολή των $x_A = \begin{bmatrix} 1 \\ 3 \end{bmatrix}$ και $x_B = \begin{bmatrix} 3 \\ -1 \end{bmatrix}$ στον άξονα που ορίζεται από το w είναι:

$$y_A = \frac{w^T \cdot x_A}{\|w\|} \quad \text{και} \quad y_B = \frac{w^T \cdot x_B}{\|w\|}, \quad \text{όπου} \quad \|w\| = \sqrt{(-1,374)^2 + 1,298^2} \approx 1,89$$

$$\text{Άρα } y_A = \frac{1}{1,89} \cdot \begin{bmatrix} -1,374 & 1,298 \end{bmatrix} \cdot \begin{bmatrix} 1 \\ 3 \end{bmatrix} = \begin{bmatrix} -0,727 & 0,686 \end{bmatrix} \cdot \begin{bmatrix} 1 \\ 3 \end{bmatrix} =$$

$$= -0,727 \cdot 1 + 0,686 \cdot (-1) = 3 = 1,331$$

$$y_B = \frac{1}{1,89} \cdot \begin{bmatrix} -1,374 & 1,258 \end{bmatrix} \cdot \begin{bmatrix} 3 \\ -1 \end{bmatrix} = \begin{bmatrix} -0,727 & 0,686 \end{bmatrix} \cdot \begin{bmatrix} 3 \\ -1 \end{bmatrix} =$$

$$= -0,727 \cdot 3 + 0,686 \cdot (-1) = -2,867$$

**** Αναλυτικά ο πολλαπλασιασμός:**


$$\begin{bmatrix} 0,496 & -0,191 \\ -0,191 & 0,458 \end{bmatrix} \cdot \begin{bmatrix} -2 \\ 2 \end{bmatrix} = \begin{bmatrix} 0,496 \cdot (-2) + (-0,191) \cdot 2 \\ -0,191 \cdot (-2) + 0,458 \cdot 2 \end{bmatrix} =$$

$$= \begin{bmatrix} -0,992 - 0,382 \\ 0,382 + 0,916 \end{bmatrix} = \begin{bmatrix} -1,374 \\ 1,298 \end{bmatrix}$$

Θέμα 3 - Linear Discriminant Analysis (LDA) vs PCA

Μέρος 1


Πρωτίστως, φορτώσαμε τα δεδομένα στην μεταβλητή X και μετά τα κανονικοποιήσαμε. Υλοποιήσαμε τον αλγόριθμο LDA για προβλήματα 2 κλάσεων στην συνάρτηση `fisherLinearDiscriminant`, η οποία επιστρέφει το διάνυσμα πάνω στο οποίο θα προβληθούν τα δεδομένα. Έγινε projection, ώστε να δημιουργηθούν τα δείγματα μειωμένης διάστασης. Ανακατασκευάστηκαν τα δείγματα μειωμένης διάστασης στον 2D χώρο προβάλλοντας τα πάνω στην κατεύθυνση του διανύσματος προβολής LDA και σχεδιάζοντας τα δείγματα μειωμένης διάστασης πάνω στην ίδια εικόνα. Τέλος, εφαρμόσαμε τη ίδια διαδικασία με την μέθοδο PCA και συγκρίναμε με την LDA.



Παρατηρούμε ότι ο LDA επιτυγχάνει την κατηγοριοποίηση των δεδομένων, αφού γνωρίζει τα class labels και προσπαθεί τη βέλτιστη κατεύθυνση, στην οποία τα means των κλάσεων έχουν τη μέγιστη απόσταση μεταξύ τους και οι within class variances είναι ελάχιστες. Αντίθετα, ο PCA μη έχοντας πληροφορίες για τα class labels, προσπαθεί να βρει την κατεύθυνση που μεγιστοποιεί τη διασπορά των δεδομένων, με αποτέλεσμα η απόσταση των δεδομένων από τη γραμμή διαχωρισμού να είναι μεγάλη αλλά να μην διαχωρίζει επιτυχώς οι 2 κλάσεις. Συνεπώς, ο LDA μπορεί να χρησιμοποιηθεί ως classifier, ενώ ο PCA όχι.

Μέρος 2

Αρχικά, φορτώσαμε τα δεδομένα και μετά τα κανονικοποιήσαμε. Υλοποιήσαμε την συνάρτηση myLDA, η οποία θα δέχεται στην είσοδο τα κανονικοποιημένα δείγματα, τα labels και τον αριθμό των διαστάσεων με σκοπό να μειώσει τις διαστάσεις των δειγμάτων σε 2. Επιστρέφει έναν πίνακα που περιέχει στις στήλες του τα διανύσματα προβολής LDA.



Παρατηρούμε ότι έχει γίνει διαχωρισμός των τριών κλάσεων και ομαδοποίηση των δεδομένων όπως περιμέναμε, καθώς ο LDA λειτουργεί καλύτερα ως classifier και για μεγάλο αριθμό κλάσεων.

Θέμα 4 - Bayes

1)+4)

$$\mu_1 = \begin{pmatrix} 2 \\ 3 \end{pmatrix}, \mu_2 = \begin{pmatrix} 4 \\ 4 \end{pmatrix}, \Sigma_1 = \begin{pmatrix} 2 & 0,5 \\ 0,5 & 1 \end{pmatrix}, \Sigma_2 = \begin{pmatrix} 1,5 & -0,3 \\ -0,3 & 0,8 \end{pmatrix}$$

2) Το εύρος απόφασης θα προέρξει από την εξίσωση:

$$P(w_1)P(x|w_1) = P(w_2)P(x|w_2) \text{ όπου:}$$

$$\bullet P(x|w_1) = \frac{1}{\sqrt{(2\pi)^2 \cdot |\Sigma_1|}} \cdot e^{-\frac{1}{2}(\vec{x} - \vec{\mu}_1)^T \Sigma_1^{-1} (\vec{x} - \vec{\mu}_1)} \text{ και}$$

$$\bullet P(x|w_2) = \frac{1}{\sqrt{(2\pi)^2 \cdot |\Sigma_2|}} \cdot e^{-\frac{1}{2}(\vec{x} - \vec{\mu}_2)^T \Sigma_2^{-1} (\vec{x} - \vec{\mu}_2)} \quad (\text{εκδόμης στο c})$$

$$\bullet |\Sigma_1| = \begin{vmatrix} 2 & 0,5 \\ 0,5 & 1 \end{vmatrix} = 2 - 0,5^2 = 1,75$$

$$\bullet |\Sigma_2| = \begin{vmatrix} 1,5 & -0,3 \\ -0,3 & 0,8 \end{vmatrix} = 1,5 \cdot 0,8 - (-0,3)^2 = 1,11$$

$$\bullet \Sigma_1^{-1} = \frac{1}{1,75} \begin{pmatrix} 1 & -0,5 \\ -0,5 & 2 \end{pmatrix} = \begin{pmatrix} 0,571 & -0,286 \\ -0,286 & 1,143 \end{pmatrix}$$

$$\bullet \Sigma_2^{-1} = \frac{1}{1,11} \begin{pmatrix} 0,8 & 0,3 \\ 0,3 & 1,5 \end{pmatrix} = \begin{pmatrix} 0,72 & 0,27 \\ 0,27 & 1,351 \end{pmatrix}$$

$$\bullet (\vec{x} - \vec{\mu}_1)^T \Sigma_1^{-1} (\vec{x} - \vec{\mu}_1) = (x_1 - 2 \quad x_2 - 3) \begin{pmatrix} 0,571 & -0,286 \\ -0,286 & 1,143 \end{pmatrix} \begin{pmatrix} x_1 - 2 \\ x_2 - 3 \end{pmatrix} =$$

$$= (x_1 - 2)[0,571(x_1 - 2) - 0,286(x_2 - 3)] + (x_2 - 3)[1,143(x_2 - 3) - 0,286(x_1 - 2)] =$$

$$= 0,571x_1^2 - 0,572x_1x_2 + 1,143x_2^2 - 0,568x_1 - 5,714x_2 + 9,139$$

$$\bullet (x-\mu_2)^T \Sigma_2^{-1} (x-\mu_2) = (x_1-4 \quad x_2-4) \begin{pmatrix} 0,72 & 0,27 \\ 0,27 & 1,351 \end{pmatrix} \begin{pmatrix} x_1-4 \\ x_2-4 \end{pmatrix} =$$

$$= (x_1-4) [0,72(x_1-4) + 0,27(x_2-4)] + (x_2-4) [0,27(x_1-4) + 1,351(x_2-4)]$$

$$= 0,72x_1^2 + 0,54x_1x_2 + 1,351x_2^2 - 7,92x_1 - 12,986x_2 + 41,776$$

Οπότε, έχουμε:

$$\bullet P(w_1) \frac{1}{\sqrt{(2\pi)^2 \cdot 1,75}} \cdot e^{-\frac{1}{2}(x-\mu_1)^T \Sigma_1^{-1} (x-\mu_1)} = P(w_2) \frac{1}{\sqrt{(2\pi)^2 \cdot 1,11}} \cdot e^{-\frac{1}{2}(x-\mu_2)^T \Sigma_2^{-1} (x-\mu_2)} \Rightarrow$$

$$\Rightarrow \ln(P(w_1)) + \ln \frac{1}{\sqrt{4\pi^2 \cdot 1,75}} - \frac{1}{2}(x-\mu_1)^T \Sigma_1^{-1} (x-\mu_1) =$$

$$= \ln(P(w_2)) + \ln \frac{1}{\sqrt{4\pi^2 \cdot 1,11}} - \frac{1}{2}(x-\mu_2)^T \Sigma_2^{-1} (x-\mu_2) \Rightarrow$$

$$\Rightarrow \ln(P(w_1)) - 2,118 - 0,286x_1^2 + 0,286x_1x_2 - 0,57x_2^2 + 0,28x_1 + 2,86x_2 - 4,57 =$$

$$= \ln(P(w_2)) - 1,89 - 0,36x_1^2 - 0,27x_1x_2 - 0,68x_2^2 + 3,96x_1 + 6,49x_2 - 20,89 \Rightarrow$$

$$\Rightarrow \ln\left(\frac{P(w_1)}{P(w_2)}\right) - 0,23 = -0,074x_1^2 - 0,556x_1x_2 - 0,11x_2^2 + 3,68x_1 + 3,63x_2 + 16,32$$

4) Για $\Sigma_1 = \Sigma_2 = \begin{pmatrix} 1,2 & 0,4 \\ 0,4 & 1,2 \end{pmatrix}$ έχουμε:

$$|\Sigma_1| = |\Sigma_2| = \begin{vmatrix} 1,2 & 0,4 \\ 0,4 & 1,2 \end{vmatrix} = 1,2^2 - 0,4^2 = 1,28$$

$$\Sigma_1^{-1} = \Sigma_2^{-1} = \frac{1}{1,28} \begin{pmatrix} 1,2 & -0,4 \\ -0,4 & 1,2 \end{pmatrix} = \begin{pmatrix} 0,94 & -0,31 \\ -0,31 & 0,94 \end{pmatrix}$$

$$(x-\mu_1)^T \Sigma_1^{-1} (x-\mu_1) = (x_1-2 \quad x_2-3) \begin{pmatrix} 0,94 & -0,31 \\ -0,31 & 0,94 \end{pmatrix} \begin{pmatrix} x_1-2 \\ x_2-3 \end{pmatrix} =$$

$$= (x_1 - 2)[0,94(x_1 - 2) - 0,31(x_2 - 3)] + (x_2 - 3)[0,94(x_2 - 3) - 0,31(x_1 - 2)] =$$

$$= 0,94x_1^2 - 0,62x_1x_2 + 0,94x_2^2 - 1,9x_1 - 4,4x_2 + 8,5$$

$$(x - \mu_2)^T \Sigma_2^{-1} (x - \mu_2) = (x_1 - 4 \quad x_2 - 4) \begin{pmatrix} 0,94 & -0,31 \\ -0,31 & 0,94 \end{pmatrix} \begin{pmatrix} x_1 - 4 \\ x_2 - 4 \end{pmatrix} =$$

$$= (x_1 - 4)[0,94(x_1 - 4) - 0,31(x_2 - 4)] + (x_2 - 4)[0,94(x_2 - 4) - 0,31(x_1 - 4)] =$$

$$= 0,94x_1^2 - 0,62x_1x_2 + 0,94x_2^2 - 5,04x_1 - 5,04x_2 + 20,16$$

Συνολικά έχουμε:

$$P(w_1) \frac{1}{\sqrt{(2\pi)^2 |\Sigma_1|}} \cdot e^{-\frac{1}{2}(x - \mu_1)^T \Sigma_1^{-1} (x - \mu_1)} = P(w_2) \frac{1}{\sqrt{(2\pi)^2 |\Sigma_2|}} \cdot e^{-\frac{1}{2}(x - \mu_2)^T \Sigma_2^{-1} (x - \mu_2)} \Rightarrow$$

$$|\Sigma_1| = |\Sigma_2|$$



$$\Rightarrow \ln(P(w_1)) - \frac{1}{2}(0,94x_1^2 - 0,62x_1x_2 + 0,94x_2^2 - 1,9x_1 - 4,4x_2 + 8,5) =$$


$$= \ln(P(w_2)) - \frac{1}{2}(0,94x_1^2 - 0,62x_1x_2 + 0,94x_2^2 - 5x_1 - 5x_2 + 20,16) \Rightarrow$$

$$\Rightarrow \ln\left(\frac{P(w_1)}{P(w_2)}\right) + 0,95x_1 + 2,2x_2 - 4,25 = 2,5x_1 + 2,5x_2 - 20,16 \Rightarrow$$


$$\Rightarrow x_1 = \frac{\ln\left(\frac{P(w_1)}{P(w_2)}\right) - 0,3x_2 + 15,91}{1,55}$$

2) Σχεδιάσαμε τις 3D απεικονίσεις και ισοϋψείς καμπύλες για κάθε κλάση.









3) Απεικονίσαμε στην ν ίδια εικόνα τα σύνορα απόφασης για τις ακόλουθες τιμές της εκ των προτέρων πιθανότητας $P(\omega_1) = 0.1, 0.25, 0.5, 0.75, 0.9$.



4) Επαναλάβαμε την ίδια διαδικασία υποθέτοντας ότι οι πίνακες συνδιασποράς είναι ίδιοι.







Παρατηρούμε ότι τα σύνορα απόφασης ενώ ήταν παραβολές τώρα βρίσκονται πάνω σε ευθείες. Όσο αυξάνεται η $P(\omega_1)$ τόσο οι ευθείες απόφασης απομακρύνονται από την $P(X|\omega_1)$ και πλησιάζουν την $P(X|\omega_2)$.

Θέμα 5 - Εξαγωγή χαρακτηριστικών και Bayes Classification

Αρχικά, δημιουργήσαμε έναν απλό ταξινομητή Bayes ο οποίος μπορεί να ταξινομεί δείγματα σε δύο κλάσεις και συγκεκριμένα στις κλάσεις $C1$ και $C2$ των ψηφίων 1 και 2 αντίστοιχα. Ενδεικτικά, εκτυπώσαμε τα 2 πρώτα ψηφία 1 και 2 για καθένα από τα χαρακτηριστικά που προσθέταμε (aspect ratio, foreground pixels, centroid). Ωστόσο, η διαφορά στις εικόνες ήταν μηδαμινή, οπότε παραθέτουμε τα ψηφία έχοντας και τα 3 χαρακτηριστικά:





Τα αποτελέσματα για την ακρίβεια ταξινόμησης κάθε φορά που προσθέτουμε ένα χαρακτηριστικό εκτυπώνονται στην κονσόλα ως εξής:

```
C:\Users\klein\AppData\Local\Programs\Python\Python312\python.exe C:\Users\klein\Desktop\HW1_2024\exercise1_5\HW1-Bayes-MNIST.py
Classification accuracy with features ['aspect_ratio']: 0.9545454545454546
Classification accuracy with features ['aspect_ratio', 'fg_pixels']: 0.9669421487603306
Classification accuracy with features ['aspect_ratio', 'fg_pixels', 'centroid']: 0.9710743801652892

Process finished with exit code 0
```

Η αναλογία διαστάσεων είναι ένα καθοριστικό χαρακτηριστικό και έτσι ο ταξινομητής πετυχαίνει μεγάλη ακρίβεια. Το ψηφίο 1 είναι ψηλό και στενό (υψηλό aspect ratio), ενώ το ψηφίο 2 είναι πιο φαρδύ και όχι τόσο ψηλό (χαμηλό aspect ratio). Παρατηρούμε ότι η ακρίβεια αυξάνεται με κάθε επιπλέον χαρακτηριστικό που προσθέτουμε.

Έπειτα, επαναλάβαμε τη διαδικασία θεωρώντας ότι έχουμε τρεις κλάσεις και συγκεκριμένα τα ψηφία 0, 1, 2. Και πάλι η διαφορά στις εικόνες ήταν μηδαμινή, οπότε παραθέτουμε τα ψηφία έχοντας και τα 3 χαρακτηριστικά:



```
C:\Users\klein\AppData\Local\Programs\Python\Python312\python.exe C:\Users\klein\Desktop\HW1_2024\exercise1_5\HW1-Bayes-MNIST.py
Classification accuracy with features ['aspect_ratio']: 0.7217125382262997
Classification accuracy with features ['aspect_ratio', 'fg_pixels']: 0.7186544342507645
Classification accuracy with features ['aspect_ratio', 'fg_pixels', 'centroid']: 0.7217125382262997

Process finished with exit code 0
```

Παρατηρούμε ότι η ακρίβεια ταξινόμησης μειώθηκε με την προσθήκη της 3ης κλάσης και αυτό είναι λογικό λόγω της αυξημένης πολυπλοκότητας που προσδίδει. Το ψηφίο 0 ενδεχομένως να έχει παρόμοια αναλογία διαστάσεων με άλλα ψηφία, με αποτέλεσμα ο ταξινομητής να μην μπορεί εύκολα να τα διαχωρίσει. Επίσης, το κέντρο βάρους και η κατανομή των pixels του μπορεί να μοιάζουν με άλλα ψηφία, οπότε η προσθήκη αυτών των χαρακτηριστικών επίσης δεν μεταβάλλει κατά πολύ το αποτέλεσμα της ταξινόμησης.

Θέμα 6 - Minimum risk

$$p(x|w_i) = \begin{cases} \frac{x}{\sigma_i^2} e^{-\frac{x}{2\sigma_i^2}}, & x \geq 0 \\ 0, & x < 0 \end{cases} \quad \text{με } \sigma_1 = 1 \text{ και } \sigma_2 = 2$$

$$L = \begin{pmatrix} 0 & 0.5 \\ 1.0 & 0 \end{pmatrix} = \begin{pmatrix} \lambda_{11} & \lambda_{12} \\ \lambda_{21} & \lambda_{22} \end{pmatrix}$$

$$l_1 = \lambda_{11}^{\text{opt}} P(w_1) P(x|w_1) + \lambda_{21} P(w_2) P(x|w_2) = P(w_2) \cdot P(x|w_2)$$

$$l_2 = \lambda_{12} P(w_1) P(x|w_1) + \lambda_{22}^{\text{opt}} P(w_2) P(x|w_2) = \frac{1}{2} P(w_1) \cdot P(x|w_1)$$

Για να ανήκει το x στο w_1 πρέπει $l_1 < l_2$, ενώ για να ανήκει στο w_2 πρέπει $l_1 > l_2$. Οπότε, το όριο απόφασης βρίσκεται στο $l_1 = l_2$.

$$l_1 = l_2 \Rightarrow P(w_2) P(x_0|w_2) = \frac{1}{2} P(w_1) \cdot P(x_0|w_1) \Rightarrow$$

$$\Rightarrow \frac{x_0}{4} \cdot e^{-\frac{x_0^2}{8}} = \frac{1}{2} \cdot x_0 \cdot e^{-\frac{x_0^2}{2}} \Rightarrow$$

$$\Rightarrow \ln\left(\frac{1}{2} e^{-\frac{x_0^2}{8}}\right) = \ln\left(e^{-\frac{x_0^2}{2}}\right) \Rightarrow$$

$$\Rightarrow -\frac{x_0^2}{8} - \ln 2 = -\frac{x_0^2}{2} \Rightarrow$$

$$\Rightarrow -x_0^2 - 8\ln 2 = -4x_0^2 \Rightarrow$$

$$\Rightarrow x_0 = \pm \sqrt{\frac{8\ln 2}{3}} \xrightarrow{x_0 \geq 0}$$

$$\Rightarrow x_0 = \sqrt{\frac{8\ln 2}{3}}$$